

MVP | Data Engineering

Pipeline de Dados: Veículos Elétricos vs. Combustão
Fatores Associados à Adoção de EV no Mundo (2010-2025)

Aluno: João Guilherme Cartaxo Loureiro

E-mail: joaogcl.br@gmail.com

Sprint: Engenharia de Dados

Matricula: 4052026000083

Sumário

Contextualização e objetivos gerais	3
Detalhamento do projeto.....	3
Dados e ferramentas selecionadas.....	3
Coleta e carregamento de dados	4
Modelagem de dados.....	4
Definição do grão	4
Descoberta que define o modelo.....	4
Esquema - constelação de fatos	4
Linhagem	5
Catálogo de dados.....	5
Carga	6
Criação do schema e camada bronze	6
Camada silver - limpeza e conformação	7
Camada gold - dimensões com surrogate keys	7
Camada gold - fato de vendas (país × ano × segmento)	7
Camada gold - fato de contexto (país × ano)	7
Análise de dados	8
Qualidade de dados	8
Completude (nulos) e duplicatas	8
Integridade interna (as partes somam o total).....	8
Colunas derivadas e redundantes	9
Outliers (discutir, não são erros).....	9
Solução do problema proposto	9
Q1 - Participação de EV por região e período.....	10
Q2 - Ano em que cada país se tornou EV-dominante.....	11
Q3 - Adoção vs. subsídio e infraestrutura de recarga	12
Q4 - Preço relativo combustível × eletricidade vs. adoção	14
Q5 - Renda e urbanização vs. adoção	16
Q6 - Crescimento de EV vs. emissões de transporte	18
Q7 - Segmento que lidera a transição	20
Considerações finais.....	21
Pontos de melhoria	21
Autoavaliação.....	21

Contextualização e Objetivos Gerais

A transição de veículos com motor a combustão interna (ICE) para veículos elétricos a bateria (EV) é um dos movimentos estruturais mais relevantes da indústria automotiva na última década. Entre 2010 e 2025 diferentes países avançaram nessa transição em ritmos muito distintos, influenciados por políticas públicas, infraestrutura, preços de energia, renda e regulação ambiental.

Compreender quais fatores mais se associam à adoção de EV é útil tanto para formuladores de política pública quanto para montadoras, comercializadoras de energia e investidores. Nesse contexto, o objetivo deste trabalho é construir um pipeline de dados de ponta a ponta na nuvem capaz de comparar países, regiões e segmentos de veículo e de identificar quais variáveis mais se associam à participação de mercado dos elétricos (subsídio, infraestrutura de recarga, preço de combustível e de eletricidade, renda, urbanização e regulação).

Perguntas de Negócio

As perguntas abaixo foram definidas antes de qualquer outra etapa e não serão removidas mesmo que alguma não seja plenamente respondida ao longo do trabalho. A discussão de suas respostas será feita na Autoavaliação.

- 1) Como evoluiu a participação de EV (`ev_market_share`) por região e segmento entre 2010 e 2025?
- 2) Quais países se tornaram “EV-dominantes” e a partir de que ano?
- 3) Subsídio (`ev_subsidy_usd`) e infraestrutura de recarga se associam a maior adoção?
- 4) O preço relativo entre combustível e eletricidade se associa às vendas de EV?
- 5) Renda (`gdp_per_capita`) e urbanização explicam parte da adoção?
- 6) O crescimento de EV veio acompanhado de queda nas emissões de transporte?
- 7) Qual segmento (`premium`, `mass_market` ou `commercial`) lidera a transição?

Detalhamento do Projeto

Dados e Ferramentas Selecionadas

A fonte de dados escolhida foi um conjunto tabular único em formato CSV:

`ev_vs_petro_dataset_v3.csv` é uma base pública de mercado que consolida vendas de veículos e variáveis macroeconômicas e de infraestrutura por país, ano e segmento.

A base possui 1.200 linhas × 22 colunas, cobrindo 25 países, 5 regiões, os anos de 2010 a 2025 e 3 segmentos de veículo. O grão natural do dado é país × ano × segmento ($25 \times 16 \times 3 = 1.200$ linhas).

Todo o projeto foi executado na plataforma Databricks em sua versão Community Edition. Os scripts de coleta, modelagem e carga foram desenvolvidos em notebooks Python com PySpark, a persistência foi feita em tabelas Delta e a etapa de análise foi conduzida em Spark SQL sobre as tabelas da camada gold.

Coleta e Carregamento de Dados

A coleta consistiu no upload do arquivo CSV para o armazenamento em nuvem do Databricks. Na Community Edition, o caminho é Data → Create Table → Upload File; o arquivo é persistido no diretório `/FileStore/tables/`.

Em seguida, o arquivo foi lido com Spark e sua forma foi conferida:

```
3 minutos ago (45s) 1: Cell 1 Python
#Leitura do arquivo bruto com Spark e conferência da forma
df_raw = spark.table("default.ev_vs_petrol_dataset_v_3")

print("Linhas:", df_raw.count(), "| Colunas:", len(df_raw.columns))
df_raw.printSchema()
display(df_raw.limit(5))

> See performance (2) ✓ Checked for improvements
```

Figura 1 - Leitura do arquivo bruto com Spark e conferência da forma

O resultado confirma 1.200 linhas × 22 colunas. Eventuais tipos incorretos inferidos pelo inferSchema são corrigidos posteriormente na camada silver.

Modelagem de Dados

Definição do Grão

Confirma-se por código que não há duas linhas para a mesma combinação país × ano × segmento:

```
Just now (2s) 2 Python
#Confirmação do grão país x ano x segmento
from pyspark.sql import functions as F

total = df_raw.count()
distintos = df_raw.select("country", "year", "vehicle_segment").distinct().count()
print("Linhas:", total, "| Combinações distintas:", distintos) # 1200 e 1200 -> grão confirmad

> See performance (2) Optimize
```

Figura 2 - Confirmação do grão país × ano × segmento

Descoberta que Define o Modelo

Verificou-se quais colunas variam por segmento e quais são constantes dentro de país × ano:

```
09:22 AM (7s) 3 Python
#Teste de variação das colunas de contexto por segmento
macro = ["gdp_per_capita", "fuel_price_usd_per_liter", "electricity_price_usd_per_kwh",
         "urban_population_percent", "co2_emissions_transport_mt", "emission_regulation_score",
         "ev_subsidy_usd", "charging_stations", "avg_ev_range_km", "fast_chargers_share"]

for c in macro:
    n = (df_raw.groupBy("country", "year").agg(F.countDistinct(c).alias("n")))
        .filter("n > 1").count()
    print(f"{c:32s} -> país-ano variando por segmento: {n}") # esperado: 0 para todas

> See performance (10) ✓ Checked for improvements
```

Figura 3 - Teste de variação das colunas de contexto por segmento

Todas as 10 colunas retornaram 0: elas descrevem o contexto do país no ano, não a venda por segmento. Consequência prática: se ficassem no fato de vendas, ao somar entre os 3 segmentos o valor seria triplicado. Por isso são alocadas no grão país × ano, configurando uma constelação de fatos.

Esquema - Constelação de Fatos

fato_vendas - grão país × ano × segmento:

- **Medidas aditivas:** ev_sales, petrol_car_sales, diesel_car_sales, total_vehicle_sales
- **Medidas não aditivas:** ev_market_share, ev_growth_rate_yoy, is_ev_dominant
- **Chaves estrangeiras:** sk_tempo, sk_geografia, sk_segmento

fato_contexto_pais_ano - grão país × ano:

- gdp_per_capita, fuel_price_usd_per_liter, electricity_price_usd_per_kwh, urban_population_percent, co2_emissions_transport_mt, emission_regulation_score, ev_subsidy_usd, charging_stations, avg_ev_range_km, fast_chargers_share
- **Chaves estrangeiras:** sk_tempo, sk_geografia

Dimensões

- dim_tempo (year → década, período pré/pós-2020)
- dim_geografia (country → region)
- dim_segmento (vehicle_segment)

Sobre a coluna powertrain_type (apenas ICE/BEV, com 36 linhas BEV das 1.200): Rótulo derivado da dominância, redundante com is_ev_dominant. Decisão adotada: não incluí-la no modelo, usando-a apenas em validação cruzada na análise de qualidade.

Linhagem

Fluxo: CSV único (fonte da coleta) → bronze (cru) → silver (limpo e conformado) → gold (fato_vendas, fato_contexto_pais_ano e 3 dimensões). As dimensões saem de SELECT DISTINCT da silver e as surrogate keys são geradas no carregamento. Ao final, o modelo relacional reduz-se a duas tabelas-fato ligadas às dimensões compartilhadas de tempo e geografia.

Catálogo de Dados

O catálogo abaixo descreve cada atributo, seu tipo e seu domínio. Os domínios numéricos (mínimo–máximo) e os domínios categóricos foram gerados por código sobre a base e conferidos manualmente, conforme o bloco a seguir:

```

#Geração dos domínios do catálogo por código
num_cols = ["year", "ev_sales", "petrol_car_sales", "diesel_car_sales", "total_vehicle_sales",
            "ev_market_share", "charging_stations", "fast_chargers_share", "avg_ev_range_km",
            "fuel_price_usd_per_liter", "electricity_price_usd_per_kwh", "gdp_per_capita",
            "urban_population_percent", "co2_emissions_transport_mt", "ev_subsidy_usd",
            "emission_regulation_score", "ev_growth_rate_yoy"]
cat_cols = ["country", "region", "vehicle_segment", "powertrain_type", "is_ev_dominant"]

display(df_raw.select([f.min(c).alias(f"min_{c}") for c in num_cols] +
                      [f.max(c).alias(f"max_{c}") for c in num_cols]))
for c in cat_cols:
    print(c, "=>", [r[0] for r in df_raw.select(c).distinct().collect()])

```

Figura 4 - Geração dos domínios do catálogo por código

As saídas do bloco acima alimentam as tabelas 1 e 2 a seguir.

1. Atributos Numéricos

Atributo	Tipo	Descrição	Domínio (mín – máx)
year	inteiro	Ano de referência	2010 – 2025
ev_sales	inteiro ≥ 0	Vendas de veículos elétricos no grão	5 – 7.670.056
petrol_car_sales	inteiro ≥ 0	Vendas de carros a gasolina	1.727 – 14.773.694
diesel_car_sales	inteiro ≥ 0	Vendas de carros a diesel	150 – 2.014.595
total_vehicle_sales	inteiro ≥ 0	= ev + petrol + diesel (verificado)	17.480 – 18.849.977
ev_market_share	% (0–100)	Participação de EV = ev_sales/total×100	0 – 95
ev_growth_rate_yoy	%	Crescimento anual de EV (limite superior aparente de 300%)	–40,96 – 300

Atributo	Tipo	Descrição	Domínio (mín – máx)
<i>charging_stations</i>	inteiro ≥ 0	Estações de recarga no país-ano	0 – 4.338.106
<i>fast_chargers_share</i>	% (0–100)	Proporção de carregadores rápidos	0 – 49,3
<i>avg_ev_range_km</i>	inteiro	Autonomia média dos EV (km)	106 – 507
<i>fuel_price_usd_per_liter</i>	decimal	Preço do combustível (USD/litro)	0,483 – 2,153
<i>electricity_price_usd_per_kwh</i>	decimal	Preço da eletricidade (USD/kWh)	0,067 – 0,379
<i>gdp_per_capita</i>	inteiro	PIB per capita (USD)	1.359 – 103.437
<i>urban_population_percent</i>	% (0–100)	População urbana	30,9 – 98,5
<i>co2_emissions_transport_mt</i>	decimal	Emissões de CO ₂ do transporte (Mt)	5,4 – 1.900,8
<i>ev_subsidy_usd</i>	inteiro ≥ 0	Subsídio médio por EV (USD)	0 – 8.952
<i>emission_regulation_score</i>	decimal	Índice de rigor da regulação de emissões	19,48 – 95,60

Tabela 1 - Catálogo e domínios dos atributos numéricos

2. Atributos Categóricos

Atributo	Tipo	Descrição	Domínio
<i>country</i>	categórico	País (25 valores)	Australia, Brazil, China, Germany, Norway, ... (25 países)
<i>region</i>	categórico	Região do país	APAC, Europe, North America, Oceania, South America
<i>vehicle_segment</i>	categórico	Segmento do veículo	commercial, mass_market, premium
<i>powertrain_type</i>	categórico	Motorização dominante (não usada no modelo)	ICE, BEV
<i>is_ev_dominant</i>	binário	1 quando <i>ev_market_share</i> > 50%	0, 1

Tabela 2 - Catálogo e domínios dos atributos categóricos

Carga

A carga adota a arquitetura medalhão (bronze → silver → gold), aplicando ETL com Spark e persistência em tabelas Delta. As transformações estão documentadas passo a passo abaixo.

Criação do Schema e Camada Bronze

```

#Criação do schema e persistência da camada bronze
spark.sql("CREATE SCHEMA IF NOT EXISTS ev_mvp")
spark.sql("USE ev_mvp")

#Bronze: dados crus, sem alteração
(df_raw.write.format("delta").mode("overwrite")
  .option("overwriteSchema", "true")
  .saveAsTable("ev_mvp.bronze_vendas"))

```

Figura 5 - Criação do schema e persistência da camada bronze

Camada Silver - Limpeza e Conformação

As transformações padronizam os campos categóricos (evitando duplicatas por espaço ou caixa) e garantem os tipos numéricos.

```
Aug 30, 2025 (8s) 7 Python

#Transformações da camada silver
df_silver = (spark.table("ev_mvp.bronze_vendas")
    .withColumn("country", F.trim("country"))
    .withColumn("region", F.trim("region"))
    .withColumn("vehicle_segment", F.lower(F.trim("vehicle_segment")))
    .withColumn("year", F.col("year").cast("int"))
    .withColumn("ev_sales", F.col("ev_sales").cast("long"))
    .withColumn("total_vehicle_sales", F.col("total_vehicle_sales").cast("long")))

(df_silver.write.format("delta").mode("overwrite")
    .option("overwriteSchema", "true")
    .saveAsTable("ev_mvp.silver_vendas"))

See performance (1) Checked for improvements
```

Figura 6 - Transformações da camada silver

Camada Gold - Dimensões com Surrogate Keys

```
Just now (11s) 8 Python

#Construção das dimensões com chaves substitutas
from pyspark.sql.window import Window

df_silver = spark.table("ev_mvp.silver_vendas")

dim_tempo = (df_silver.select("year").distinct()
    .withColumn("sk_tempo", F.row_number().over(Window.orderBy("year")))
    .withColumn("decada", (F.floor(F.col("year")/10)*10).cast("int"))
    .withColumn("periodo", F.when(F.col("year") >= 2020, "pos_2020").otherwise("pre_2020")))

dim_geografia = (df_silver.select("country", "region").distinct()
    .withColumn("sk_geografia", F.row_number().over(Window.orderBy("region", "country"))))

dim_segmento = (df_silver.select("vehicle_segment").distinct()
    .withColumn("sk_segmento", F.row_number().over(Window.orderBy("vehicle_segment"))))

for nome, dim in [("dim_tempo", dim_tempo), ("dim_geografia", dim_geografia),
    ("dim_segmento", dim_segmento)]:
    (dim.write.format("delta").mode("overwrite").option("overwriteSchema", "true")
        .saveAsTable(f"ev_mvp.{nome}"))

See performance (3) Checked for improvements
```

Figura 7 - Construção das dimensões com chaves substitutas

Camada Gold - Fato de Vendas (país × ano × segmento)

```
Just now (6s) 9 Python

#Construção do fato de vendas
fato_vendas = (df_silver
    .join(dim_tempo.select("year", "sk_tempo"), "year")
    .join(dim_geografia.select("country", "region", "sk_geografia"), ["country", "region"])
    .join(dim_segmento.select("vehicle_segment", "sk_segmento"), "vehicle_segment")
    .select("sk_tempo", "sk_geografia", "sk_segmento",
        "ev_sales", "petrol_car_sales", "diesel_car_sales", "total_vehicle_sales",
        "ev_market_share", "ev_growth_rate_yoy", "is_ev_dominant"))

(fato_vendas.write.format("delta").mode("overwrite").option("overwriteSchema", "true")
    .saveAsTable("ev_mvp.fato_vendas"))
print("fato_vendas:", spark.table("ev_mvp.fato_vendas").count(), "linhas (esperado 1200)")

See performance (2) Checked for improvements
```

Figura 8 - Construção do fato de vendas

Camada gold - Fato de Contexto (país × ano)

```
Just now (5s) 10 Python

#Construção do fato de contexto por país-ano
macro_cols = ["gdp_per_capita", "fuel_price_usd_per_liter", "electricity_price_usd_per_kwh",
    "urban_population_percent", "co2_emissions_transport_mt", "emission_regulation_score",
    "ev_subsidy_usd", "charging_stations", "avg_ev_range_km", "fast_chargers_share"]

fato_contexto = (df_silver
    .select(["country", "region", "year"] + macro_cols)
    .dropDuplicates(["country", "year"])
    .join(dim_tempo.select("year", "sk_tempo"), "year")
    .join(dim_geografia.select("country", "region", "sk_geografia"), ["country", "region"])
    .select(["sk_tempo", "sk_geografia"] + macro_cols))


(fato_contexto.write.format("delta").mode("overwrite").option("overwriteSchema", "true")
    .saveAsTable("ev_mvp.fato_contexto_pais_ano"))
print("contexto:", spark.table("ev_mvp.fato_contexto_pais_ano").count(), "linhas (esperado 400)")

See performance (2) Checked for improvements
```

Figura 9 - Construção do fato de contexto por país-ano

Transformação-chave: Acima, o dropDuplicates(country, year) colapsa os 3 segmentos em uma linha por país-ano, evitando a tripla contagem discutida na Modelagem.

Ao final há 5 tabelas Delta no schema ev_mvp: 2 fatos (1.200 e 400 linhas) e 3 dimensões.



Name	Owner	Created at	Popularity	Comment
bronze_vendas	jogcl@yahoo.com.br	Aug 23, 2026, 11:50 AM		
dim_geografia	jogcl@yahoo.com.br	Aug 30, 2026, 11:42 AM		
dim_segmento	jogcl@yahoo.com.br	Aug 30, 2026, 11:42 AM		
dim_tempo	jogcl@yahoo.com.br	Aug 30, 2026, 11:42 AM		
fato_contexto_pais_ano	jogcl@yahoo.com.br	Aug 30, 2026, 11:49 AM		
fato_vendas	jogcl@yahoo.com.br	Aug 30, 2026, 11:49 AM		
silver_vendas	jogcl@yahoo.com.br	Aug 30, 2026, 11:41 AM		

Figura 10 - Tabelas e Fatos

Análise de Dados

A análise divide-se em dois momentos: a avaliação da qualidade dos dados e a solução do problema por meio das perguntas de negócio.

Qualidade de Dados

Os testes abaixo foram executados sobre a camada bronze.

Compleitude (nulos) e duplicatas

```

#Teste de nulos e duplicatas
b = spark.table("ev_mvp.bronze_vendas")
display(b.select([F.sum(F.col(c).isNull().cast("int")).alias(c) for c in b.columns])) # esperado 0
print("Duplicatas completas:", b.count() - b.dropDuplicates().count()) # esperado 0

```

Figura 11 - Teste de Nulos e Duplicatas

Resultado: nenhum valor nulo em qualquer das 22 colunas e nenhuma linha completamente duplicada. A base está completa no grão definido.

Integridade interna de vendas (as partes somam o total)

```

#Teste de integridade (vendas de veículos)
inconsistentes = b.filter(
    (F.col("ev_sales") + F.col("petrol_car_sales") + F.col("diesel_car_sales"))
    != F.col("total_vehicle_sales")).count()
print("Linhas onde ev+petrol+diesel != total:", inconsistentes) # esperado 0

```

Figura 12 - Teste de Integridade

Resultado: 0 linhas inconsistentes. A identidade $ev_sales + petrol_car_sales + diesel_car_sales = total_vehicle_sales$ vale para toda a base, o que valida a aditividade das medidas do fato de vendas.

Colunas derivadas e redundantes

```

#Teste de colunas redundantes
chk = b.withColumn("share_calc", F.round(F.col("ev_sales")/F.col("total_vehicle_sales")*100, 2))
print("Divergências de market_share:")
chk.filter(F.abs(F.col("share_calc")-F.col("ev_market_share")) > 0.01).count()
display(b.groupBy("is_ev_dominant").agg(F.min("ev_market_share"), F.max("ev_market_share")))

```

Figura 13 - Teste de Colunas Redundantes

Achados: ev_market_share reproduz exatamente $ev_sales/total_vehicle_sales$ | 0 divergências acima de 0,01. E $is_ev_dominant = 1$ ocorre precisamente quando o share ultrapassa ~50%, conforme a tabela:

is_ev_dominant	min(ev_market_share)	max(ev_market_share)
0	0,00	49,87
1	50,56	95,00

Tabela 3 - Confirmação de que $is_ev_dominant$ deriva do market share

Registra-se que ambas as colunas são derivadas: são mantidas por conveniência de consulta, mas nunca são somadas. Os cálculos usam sempre ev_sales e $total_vehicle_sales$.

Outliers (discutir, não são erros)

```

#Verificação de outliers
display(b.select(F.min("ev_growth_rate_yoy"), F.max("ev_growth_rate_yoy")))
display(b.filter("ev_growth_rate_yoy" >= 300).select("country", "year", "ev_sales", "ev_growth_rate_yoy"))

```

Figura 14 - Verificação de Outliers

A coluna $ev_growth_rate_yoy$ varia de -40,96% a 300%, e há 43 linhas exatamente em 300%, indício de um teto artificial na fonte. Esses valores máximos concentram-se nos primeiros anos da série, quando a base instalada de EV era próxima de zero e qualquer variação absoluta produz percentuais enormes. Não são erros, mas exigem cautela: taxas de crescimento sobre bases minúsculas não devem ser interpretadas isoladamente.

Solução do Problema Proposto

As respostas foram obtidas em Spark SQL sobre as tabelas gold. Para cada pergunta apresentam-se a consulta e a discussão do resultado.

Q1 - Participação de EV por Região e Período

The screenshot shows a SQL query execution interface. The query is as follows:

```

%sql
SELECT g.region, t.período, ROUND(AVG(f.ev_market_share), 2) AS share_medio
FROM ev_mv.fato_vendas f
JOIN ev_mv.dim_geografia g ON f.sk_geografia = g.sk_geografia
JOIN ev_mv.dim_tempo t ON f.sk_tempo = t.sk_tempo
GROUP BY g.region, t.período
ORDER BY g.region, t.período

```

The results are displayed in a table with 10 rows and 3 columns: region, período, and share_medio. The data is as follows:

	region	período	share_medio
1	APAC	pos_2020	7.14
2	APAC	pre_2020	0.41
3	Europe	pos_2020	21.29
4	Europe	pre_2020	2.07
5	North America	pos_2020	5.87
6	North America	pre_2020	0.56
7	Oceania	pos_2020	6.26
8	Oceania	pre_2020	0.2
9	South America	pos_2020	1.57
10	South America	pre_2020	0.02

The interface also shows a status bar indicating 10 rows, 3.118s runtime, and a note that the result is stored as _sqlidf and can be used in other Python and SQL cells.

Figura 15 - Resposta da Questão 1

Região	pré-2020 (share médio)	pós-2020 (share médio)
Europe	2,07	21,29
APAC	0,41	7,14
Oceania	0,20	6,26
North America	0,56	5,87
South America	0,02	1,57

Tabela 4 - Participação média de EV por região, antes e depois de 2020

A adoção deu um salto em todas as regiões após 2020, mas de forma muito desigual. A Europa lidera com folga, saindo de 2,07% para 21,29% de participação média, cerca de dez vezes mais. APAC, Oceania e América do Norte formam um bloco intermediário (entre 5,9% e 7,1% no pós-2020), enquanto a América do Sul permanece incipiente (1,57%). A resposta é clara: a transição é liderada pela Europa e concentrada no período pós-2020.

Q2 - Ano em que cada país se tornou EV-dominante




Figura 16 - Resposta da Questão 2

País	Ano em que virou EV-dominante
Norway	2019
Sweden	2021
Netherlands	2025
China	2025

Tabela 5 - Países que atingiram participação de EV acima de 50%

Apenas 4 dos 25 países cruzaram o limiar de 50% de participação em algum segmento no período. A Noruega foi pioneira (2019), seguida pela Suécia (2021). Holanda e China chegaram somente em 2025. O resultado reforça a Q1: a dominância é rara e fortemente europeia, com a China surgindo como o grande caso não europeu ao final da série.

Q3 - Adoção vs. subsídio e infraestrutura de recarga




Figura 17 - Resposta da Questão 3




Figura 18 - Avaliação Complementar da Resposta da Questão 3

Sobre o país-ano, a correlação entre participação de EV e infraestrutura de recarga é positiva e moderada ($r = 0,24$), enquanto a correlação com subsídio é praticamente nula e até levemente negativa ($r = -0,06$). O caso mais ilustrativo aparece no topo do ranking: a Noruega concentra as maiores participações (acima de 70%) com subsídio registrado igual a zero e uma malha de recarga muito densa. Isso sugere que, nesta base, a disponibilidade de recarga acompanha a adoção com mais consistência do que o subsídio direto (coerente com o histórico norueguês), em que os incentivos foram sendo retirados à medida que o mercado amadureceu.

Q4 - Preço relativo combustível × eletricidade vs. adoção

Reutiliza-se a junção da Q3 entre os dois fatos, trocando as medidas de contexto pelos preços de combustível e eletricidade e pela razão entre ambos:

10:31 AM (2s) 34

```
%sql
SELECT g.country, t.year,
       AVG(v.ev_market_share) AS share_ev,
       c.fuel_price_usd_per_liter, c.electricity_price_usd_per_kwh,
       ROUND(c.fuel_price_usd_per_liter / c.electricity_price_usd_per_kwh, 2) AS razao_fuel_elec
FROM ev_mv.fato_vendas v
JOIN ev_mv.dim_geografia g ON v.sk_geografia = g.sk_geografia
JOIN ev_mv.dim_tempo t ON v.sk_tempo = t.sk_tempo
JOIN ev_mv.fato_contexto_pais_ano c
  ON v.sk_geografia = c.sk_geografia AND v.sk_tempo = c.sk_tempo
GROUP BY g.country, t.year, c.fuel_price_usd_per_liter, c.electricity_price_usd_per_kwh
ORDER BY share_ev DESC;
```

See performance (1) ✓ Checked for improvements

	country	year	share_ev	fuel_price_usd_per_liter	electricity_price_usd_per_kwh	razao_fuel_elec
1	Norway	2022	72.08	2.143	0.159	13.48
2	Norway	2023	71.08	2.153	0.168	12.82
3	Norway	2025	70.42999999999999	2.04	0.144	14.17
4	Norway	2024	70.20666666666666	2.09	0.155	13.48
5	Norway	2021	61.87999999999999	2.063	0.131	15.75
6	Norway	2020	51.20333333333333	1.887	0.097	19.45
7	Sweden	2025	48.71333333333333	1.93	0.141	13.69
8	Sweden	2024	47.19	2	0.155	12.9
9	Sweden	2022	46.54333333333333	2.093	0.164	12.76
10	Sweden	2023	45.10666666666666	2.097	0.168	12.48
11	Norway	2019	39.12666666666666	1.747	0.082	21.3
12	China	2025	37.97666666666667	1.18	0.09	13.11
13	Sweden	2021	37.30666666666666	1.983	0.14	14.16
14	Netherlands	2025	34.13333333333333	2.08	0.279	7.46
15	China	2024	31.57333333333333	1.233	0.088	14.01

400 rows 2.274s runtime Refreshed 1h ago

This result is stored as `_sql1df` and can be used in other Python and SQL cells.

Figura 19 - Resposta da Questão 4

10:31 AM (3s) 35

```
%sql
SELECT
  ROUND(corr(share_ev, fuel_price_usd_per_liter), 3) AS corr_combustivel,
  ROUND(corr(share_ev, electricity_price_usd_per_kwh), 3) AS corr_eletricidade,
  ROUND(corr(share_ev, razao_fuel_elec), 3) AS corr_razao
FROM (
  SELECT g.country, t.year,
         AVG(v.ev_market_share) AS share_ev,
         c.fuel_price_usd_per_liter,
         c.electricity_price_usd_per_kwh,
         c.fuel_price_usd_per_liter / c.electricity_price_usd_per_kwh AS razao_fuel_elec
  FROM ev_mv.fato_vendas v
  JOIN ev_mv.dim_geografia g ON v.sk_geografia = g.sk_geografia
  JOIN ev_mv.dim_tempo t ON v.sk_tempo = t.sk_tempo
  JOIN ev_mv.fato_contexto_pais_ano c
    ON v.sk_geografia = c.sk_geografia AND v.sk_tempo = c.sk_tempo
  GROUP BY g.country, t.year, c.fuel_price_usd_per_liter, c.electricity_price_usd_per_kwh
);
```

See performance (1) ✓ Checked for improvements

	corr_combustivel	corr_eletricidade	corr_razao
1	0.626	0.243	0.183

1 row 2.617s runtime Refreshed 1h ago

This result is stored as `_sql1df` and can be used in other Python and SQL cells.

Figura 20 - Avaliação Complementar da Resposta da Questão 4

Variável	Correlação com share de EV
fuel_price_usd_per_liter	0,63
electricity_price_usd_per_kwh	0,24
razão combustível / eletricidade	0,18

Tabela 6 - Associação entre preços de energia e adoção de EV (país-ano)

O preço do combustível é o sinal de preço mais forte: quanto mais caro o combustível fóssil, maior a participação de EV ($r = 0,63$). O preço da eletricidade tem associação fraca e positiva, e a razão combustível/eletricidade fica em 0,18, mais fraca que o preço do combustível isolado provavelmente porque países com combustível caro também tendem a ter eletricidade relativamente cara, o que atenua a razão. A leitura de negócio é que o custo de oportunidade de continuar no ICE (combustível caro) pesa mais na decisão do que o custo de operar o EV.

Q5 - Renda e urbanização vs. adoção

Mesma junção da Q3, agora com as medidas de renda e urbanização do fato de contexto:

10:37 AM (2s) 37

```
%sql
SELECT g.country, t.year,
       AVG(v.ev_market_share) AS share_ev,
       c.gdp_per_capita, c.urban_population_percent
FROM ev_mv.fato_vendas v
JOIN ev_mv.dim_geografia g ON v.sk_geografia = g.sk_geografia
JOIN ev_mv.dim_tempo t ON v.sk_tempo = t.sk_tempo
JOIN ev_mv.fato_contexto_pais_ano c
     ON v.sk_geografia = c.sk_geografia AND v.sk_tempo = c.sk_tempo
GROUP BY g.country, t.year, c.gdp_per_capita, c.urban_population_percent
ORDER BY share_ev DESC;
```

See performance (1) ✓ Checked for improvements

	country	year	share_ev	gdp_per_capita	urban_population_percent
1	Norway	2022	72.08	103437	83.4
2	Norway	2023	71.08	100025	83.5
3	Norway	2025	70.42999999999999	96351	84.3
4	Norway	2024	70.20666666666666	94974	83.5
5	Norway	2021	61.87999999999999	95275	82.8
6	Norway	2020	51.20333333333333	84775	82.6
7	Sweden	2025	48.71333333333333	61242	89
8	Sweden	2024	47.19	57305	88.8
9	Sweden	2022	46.54333333333333	55893	88.2
10	Sweden	2023	45.10666666666666	56992	88.4
11	Norway	2019	39.12666666666666	74492	82.1
12	China	2025	37.97666666666666	13776	65.8
13	Sweden	2021	37.30666666666666	54611	88.6
14	Netherlands	2025	34.13333333333333	63891	92.7
15	China	2024	31.57333333333333	13269	65.2

400 rows 2.262s runtime Refreshed 1h ago

This result is stored as `_sqldf` and can be used in other Python and SQL cells.

Figura 21 - Resposta da Questão 5

10:38 AM (3s) 38

```
%sql
SELECT
  ROUND(corr(share_ev, gdp_per_capita), 3) AS corr_renda,
  ROUND(corr(share_ev, urban_population_percent), 3) AS corr_urbanizacao
FROM (
  SELECT g.country, t.year,
         AVG(v.ev_market_share) AS share_ev,
         c.gdp_per_capita,
         c.urban_population_percent
  FROM ev_mv.fato_vendas v
  JOIN ev_mv.dim_geografia g ON v.sk_geografia = g.sk_geografia
  JOIN ev_mv.dim_tempo t ON v.sk_tempo = t.sk_tempo
  JOIN ev_mv.fato_contexto_pais_ano c
       ON v.sk_geografia = c.sk_geografia AND v.sk_tempo = c.sk_tempo
  GROUP BY g.country, t.year, c.gdp_per_capita, c.urban_population_percent
);
```

See performance (1) ✓ Checked for improvements

	corr_renda	corr_urbanizacao
1	0.466	0.199

1 row 2.536s runtime Refreshed 1h ago

This result is stored as `_sqldf` and can be used in other Python and SQL cells.

Figura 22 - Avaliação Complementar da Resposta da Questão 5

Variável	Correlação com share de EV
gdp_per_capita	0,47
urban_population_percent	0,20

Tabela 7 - Associação entre renda, urbanização e adoção de EV

A renda per capita apresenta associação moderada e positiva ($r = 0,47$): países mais ricos adotam mais EV, o que é esperado dado o custo inicial mais alto desses veículos. A urbanização tem efeito mais fraco ($r = 0,20$), relevante, mas secundário frente à renda. Renda explica parte da adoção, porém não a totalidade, já que fatores de política e infraestrutura (Q3) e de preço (Q4) atuam em conjunto.

Q6 - Crescimento de EV vs. emissões de transporte

Aqui interessa a tendência ao longo do tempo, país a país. A consulta agrega share de EV e emissões por país-ano. A análise de tendência é feita sobre esse resultado:

10:46 AM (2s) 40

```
%sql
SELECT g.country, t.year,
       AVG(v.ev_market_share) AS share_ev,
       c.co2_emissions_transport_mt
FROM   ev_mvp.fato_vendas v
JOIN   ev_mvp.dim_geografia g ON v.sk_geografia = g.sk_geografia
JOIN   ev_mvp.dim_tempo t ON v.sk_tempo = t.sk_tempo
JOIN   ev_mvp.fato_contexto_pais_ano c
       ON v.sk_geografia = c.sk_geografia AND v.sk_tempo = c.sk_tempo
GROUP BY g.country, t.year, c.co2_emissions_transport_mt
ORDER BY g.country, t.year;
```

See performance (1) ✓ Checked for improvements

	country	year	1.2 share_ev	1.2 co2_emissions_transport_mt
1	Australia	2010	0.0066666666666667	88.7
2	Australia	2011	0.02	88.3
3	Australia	2012	0.0266666666666667	89.5
4	Australia	2013	0.0566666666666667	90
5	Australia	2014	0.0833333333333333	92.3
6	Australia	2015	0.1233333333333334	93.3
7	Australia	2016	0.16	95.3
8	Australia	2017	0.29	96.2
9	Australia	2018	0.42	97.9
10	Australia	2019	0.7733333333333333	93.3
11	Australia	2020	0.6699999999999999	89.6
12	Australia	2021	1.8733333333333333	87.1
13	Australia	2022	7.473333333333333	89.5
14	Australia	2023	7.343333333333334	90.8
15	Australia	2024	8.903333333333334	88.1

400 rows | 2.329s runtime Refreshed 58m ago

This result is stored as `_sqldf` and can be used in other Python and SQL cells.

Figura 23 - Resposta da Questão 6

10:54 AM (3s) 41

```
%sql
SELECT ROUND(corr(share_ev, co2_emissions_transport_mt), 3) AS corr_global
FROM (
  SELECT g.country, t.year,
         AVG(v.ev_market_share) AS share_ev,
         c.co2_emissions_transport_mt
  FROM   ev_mvp.fato_vendas v
  JOIN   ev_mvp.dim_geografia g ON v.sk_geografia = g.sk_geografia
  JOIN   ev_mvp.dim_tempo t ON v.sk_tempo = t.sk_tempo
  JOIN   ev_mvp.fato_contexto_pais_ano c
         ON v.sk_geografia = c.sk_geografia AND v.sk_tempo = c.sk_tempo
  GROUP BY g.country, t.year, c.co2_emissions_transport_mt
);
```

See performance (1) ✓ Checked for improvements

	1.2 corr_global
1	-0.088

1 row | 2.654s runtime Refreshed 51m ago

This result is stored as `_sqldf` and can be used in other Python and SQL cells.

Figura 24 - Avaliação Complementar da Resposta da Questão 6




Figura 25 - Avaliação Complementar da Resposta da Questão 6

Olhando toda a base ao mesmo tempo, a correlação entre participação de EV e emissões de transporte é fraca ($r = -0,09$), pois a comparação mistura países de portes muito diferentes. A tendência fica nítida quando se acompanha cada país ao longo do tempo:

País	corr(ano, share)	corr(share, CO ₂)	CO ₂ transporte (início → fim)
Norway	0,97	-0,96	11 → 5 Mt
Germany	0,88	-0,82	155 → 136 Mt
China	0,86	+0,38	566 → 829 Mt

Tabela 8 - Relação entre avanço dos EV e emissões, por país

Em economias maduras e de menor escala, como Noruega e Alemanha, o avanço dos EV vem acompanhado de queda nas emissões de transporte (correlações fortemente negativas, com o CO₂ caindo ao longo da série). Já na China, a participação de EV cresce, mas as emissões de transporte também sobem e crescimento acelerado da frota total supera o efeito da eletrificação. A resposta, portanto, é condicional: os EV se associam à redução de emissões onde a frota total está estável, mas não onde o mercado ainda cresce rapidamente.

Q7 - Segmento que lidera a transição



Figura 26 - Resposta da Questão 7

Segmento	Share médio (toda a série)	Share médio (pós-2020)
premium	9,68	22,37
mass_market	6,90	16,01
commercial	2,40	5,58

Tabela 9 - Participação média de EV por segmento

O segmento premium lidera a transição em toda a série e amplia a vantagem no pós-2020 (22,4% de participação média, contra 16,0% do mass_market e 5,6% do commercial). O padrão é coerente com o custo inicial mais alto dos EV, absorvido primeiro por compradores de veículos premium; o segmento comercial é o mais atrasado, provavelmente por depender de autonomia e infraestrutura de recarga ainda em consolidação.

Discussão geral

Consolidando as respostas, o retrato que emerge é de uma transição desigual e recente, concentrada no pós-2020 e liderada pela Europa (Q1, Q2). Entre os fatores testados, os que mais se associam à adoção de EV são, em ordem de força: o rigor da regulação de emissões ($r = 0,66$, o sinal mais forte da base), o preço do combustível fóssil (Q4, $r = 0,63$), a renda per capita (Q5, $r = 0,47$) e a infraestrutura de recarga (Q3, $r = 0,24$). O subsídio direto, isoladamente, mostrou associação desprezível (Q3). O caso da Noruega evidencia que mercados podem sustentar alta adoção mesmo após a retirada de incentivos. No plano ambiental, o avanço dos EV se traduz em queda de emissões onde a frota total é estável, mas não onde ela ainda cresce rapidamente (Q6). Por fim, a transição começa pelo segmento premium e desce gradualmente para o mass_market (Q7). Para uma comercializadora ou montadora, isso sugere priorizar mercados com regulação rigorosa e combustível caro, e produtos premium e de massa, mais do que apostar apenas em subsídio.

Considerações finais

Pontos de melhoria

No plano analítico, a base poderia ser enriquecida com fontes externas (preços de baterias, malha real de recarga e séries temporais mensais) permitindo modelar a adoção de EV de forma preditiva e não apenas descritiva. Painéis de visualização (por exemplo em ferramentas de BI) tornariam os achados das sete perguntas mais acionáveis para as áreas de negócio.

Do ponto de vista de qualidade, vale registrar as duas limitações já identificadas: a coluna `ev_growth_rate_yoy` aparenta ter um teto artificial em 300% e a base possivelmente é sintética, o que recomenda validar os padrões encontrados contra fontes primárias antes de decisões de negócio.

Autoavaliação

Avaliação do atingimento das perguntas de negócio definidas no Objetivo:

- **Questões 1 a 7 respondidas.** Todas as sete perguntas foram respondidas com os dados disponíveis, cada uma acompanhada de consulta e discussão. As respostas mais robustas foram as de share por região/período, país dominante e segmento líder. As respostas de causalidade (subsídio, preço, renda) são associativas, não causais.
- **Dificuldades.** O ponto mais delicado foi decidir o grão dos fatos. A descoberta de que 10 colunas eram constantes por país-ano levou à modelagem em constelação, evitando a tripla contagem que ocorreria num fato único. Tratar as métricas (share, `is_ev_dominant`, growth) e as limitações do cluster da Community Edition também exigiu atenção.
- **Limitações dos dados.** Base possivelmente sintética: `ev_growth_rate_yoy` aparentemente limitada a 300% e há ausência de granularidade intra-anual (dados apenas anuais).
- **Trabalhos futuros.** Enriquecer com dados externos, adicionar séries mensais, construir dashboards e evoluir para modelos preditivos de adoção.

De forma geral, considero que o objetivo do MVP foi atingido: a pipeline foi construída de ponta a ponta na nuvem, com modelagem dimensional bem justificada, carga em arquitetura medalhão e análise que conecta cada número às perguntas de negócio, dentro das limitações discutidas.